INFOGRAFÍA · MODELOS DE LENGUAJE · 2017 → 2026

De la *atención* a los agentes

Nueve años separan un artículo de Google sobre traducción automática de los sistemas que hoy programan, razonan y operan computadores durante horas. Esta es la historia en seis etapas: quién entró al juego, cómo se cerró la brecha entre modelos abiertos y cerrados, qué perillas controlan su comportamiento y qué quedó del *loro estocástico*.

2017
Attention Is All You Need: 8 autores de Google proponen el Transformer.
VASWANI ET AL. · NEURIPS

175 mil M
Parámetros de GPT-3, el salto que demostró que la escala sola desbloquea habilidades.
OPENAI · MAYO 2020

~2 meses
Lo que tardó ChatGPT en llegar a 100 millones de usuarios.
ESTIMACIÓN UBS · ENE 2023

8,0% → 1,7%
Ventaja del mejor modelo cerrado sobre el mejor abierto en Chatbot Arena.
ENE 2024 → FEB 2025 · AI INDEX

01 LA LÍNEA DE TIEMPO

ABIERTO pesos descargables · CERRADO solo vía API / app · RAZONADOR piensa antes de responder · MULTIMODAL texto + imagen / audio

ETAPA 1

Los cimientos

2017 - 2019

Una arquitectura que se paraleliza en GPU cambia qué se puede entrenar.

JUN 2017

Attention Is All You Need

Elimina la recurrencia: solo atención. Nace el **Transformer**, base de todo lo que sigue.
Vaswani et al. · Google

JUN 2018

GPT-1

Pre-entrenar con texto sin etiquetar y luego ajustar: el patrón *generative pre-trained*.
OpenAI

OCT 2018

BERT

Transformer bidireccional; domina la comprensión de texto y llega al buscador de Google en 2019.
Google
ABIERTO

FEB 2019

GPT-2

1.500 M de parámetros. OpenAI retiene la versión completa por riesgo de mal uso: primer debate público de seguridad.
OpenAI · liberado completo en nov 2019
ABIERTO

ETAPA 2

La apuesta por la escala

2020 - 2022

Más datos, más parámetros, más cómputo: el error baja de forma predecible.

ENE 2020

Leyes de escalamiento

La pérdida cae como ley de potencias con el tamaño del modelo, los datos y el cómputo.
Kaplan et al. · OpenAI

MAY 2020

GPT-3

175.000 M de parámetros. Aprende tareas con unos pocos ejemplos en el prompt (*few-shot*), sin reentrenar.
OpenAI
CERRADO

2021

Nace Anthropic

Ex-integrantes de OpenAI, con Dario y Daniela Amodei, fundan un laboratorio centrado en seguridad.
San Francisco

MAR 2021

«Stochastic Parrots»

Advierte sobre forma sin significado, sesgos heredados y costo ambiental. Nombra al *loro estocástico*.
Bender, Gebru, McMillan-Major, Mitchell

MAR 2022

InstructGPT · Chinchilla

RLHF enseña a seguir instrucciones; Chinchilla muestra que faltaban datos, no parámetros.
OpenAI · DeepMind

ETAPA 3

La explosión

nov 2022 - 2023

Una interfaz de chat convierte una tecnología de laboratorio en producto masivo. Todos entran a la carrera.

30 NOV 2022

ChatGPT

Un chat sobre GPT-3.5 ajustado con RLHF. ~100 M de usuarios en dos meses.
OpenAI
CERRADO

FEB 2023

LLaMA

Meta lo comparte con investigadores; los pesos se filtran en días y arranca la comunidad abierta.
Meta
ABIERTO

14 MAR 2023

GPT-4 y Claude

El mismo día: GPT-4 acepta imágenes como entrada; Anthropic lanza su primer Claude.
OpenAI · Anthropic
CERRADO MULTIMODAL

JUL 2023

Llama 2

Pesos abiertos con licencia de uso comercial: las empresas pueden construir encima.
Meta
ABIERTO

SEP 2023

Mistral 7B

Startup francesa, licencia Apache 2.0. Un modelo pequeño que supera a Llama 2 de 13 B.
Mistral AI · París
ABIERTO

DIC 2023

Gemini 1.0

Entrenado de forma nativa con texto, imagen, audio y video desde el inicio.
Google DeepMind
CERRADO MULTIMODAL

ETAPA 4

Ver, oír… y pensar

2024

Los modelos dejan de ser solo texto, y aparece una nueva palanca: gastar cómputo al responder.

MAR 2024

Claude 3

Familia Haiku · Sonnet · Opus: visión y 200 K tokens de contexto.
Anthropic
CERRADO MULTIMODAL

MAY 2024

GPT-4o

Omni: voz, imagen y texto en un solo modelo; conversación por voz en tiempo real.
OpenAI
CERRADO MULTIMODAL

JUL 2024

Llama 3.1 405B

El primer modelo abierto que compite de tú a tú con la frontera cerrada.
Meta
ABIERTO

SEP 2024

o1: el primer razonador

Genera una cadena de pensamiento antes de responder. Nueva ley: **más cómputo en inferencia, mejores respuestas**.
OpenAI
CERRADO RAZONADOR

DIC 2024

DeepSeek-V3

Mezcla de expertos de 671 B (37 B activos). Entrenamiento final reportado en ~5,6 M USD de cómputo.
DeepSeek · Hangzhou
ABIERTO

ETAPA 5

El razonamiento se abre

2025

Un laboratorio chino publica un razonador abierto y barato. La ventaja de la frontera se mide ahora en meses.

20 ENE 2025

DeepSeek-R1

Razonador de nivel o1 con pesos abiertos (MIT). El 27 de enero Nvidia pierde ~590.000 M USD en bolsa en un día.
DeepSeek
ABIERTO RAZONADOR

FEB 2025

Claude 3.7 Sonnet

Razonamiento híbrido: el mismo modelo responde rápido o «piensa» con un presupuesto que fija el usuario.
Anthropic
CERRADO RAZONADOR

ABR 2025

Qwen3

Familia abierta (Apache 2.0) con modo de pensamiento que se activa o desactiva.
Alibaba
ABIERTO RAZONADOR

JUL 2025

Kimi K2 · oro en la IMO

Moonshot abre un modelo de 1 billón de parámetros para agentes. Modelos de OpenAI y DeepMind logran nivel de oro en la Olimpiada de Matemáticas.
Moonshot · OpenAI · DeepMind

AGO 2025

GPT-5 y gpt-oss

GPT-5 enruta entre modo rápido y razonador. gpt-oss: los primeros pesos abiertos de OpenAI desde GPT-2.
OpenAI
RAZONADOR ABIERTO (OSS)

NOV 2025

Gemini 3

Google encabeza los rankings de preferencia al lanzarlo; la cima cambia de dueño cada pocas semanas.
Google DeepMind
CERRADO MULTIMODAL

ETAPA 6

De responder a ejecutar

2026

El foco pasa al trabajo autónomo: tareas de horas, programación y uso del computador.

ABR 2026

DeepSeek V4

Mezcla de expertos de 1,6 billones de parámetros, contexto de 1 M de tokens, licencia MIT. Su autoestimación: 3–6 meses detrás de la frontera cerrada.
DeepSeek
ABIERTO RAZONADOR

JUN - SEP 2026

Generación Claude 5

Fable 5, Sonnet 5, Opus 5 y Opus 5.5: modelos pensados para trabajo agéntico de larga duración.
Anthropic
CERRADO RAZONADOR

SEP 2026

GPT-6 Astra

Despliegue escalonado desde el 3 de septiembre; énfasis en uso del computador, ingeniería de software y ciberseguridad.
OpenAI
CERRADO RAZONADOR

02 LOS JUGADORES Y LA BRECHA

Quién entró y cuándo

Año de fundación del laboratorio (o del equipo que creó su familia de modelos)

2010	**Google DeepMind**	Gemini · Gemma · fusión con Brain en 2023
2015	**OpenAI**	GPT · o-series · gpt-oss
2021	**Anthropic**	Claude
2023	**Meta**	Llama · el abierto que abrió la puerta
2023	**Mistral AI**	Francia · Mistral, Mixtral
2023	**xAI**	Grok
2023	**DeepSeek**	China · V3, R1, V4
2023	**Alibaba · Qwen**	China · Qwen, abierta desde 2023
2023	**Moonshot AI**	China · Kimi

2023 fue el año de entrada: seis de estos nueve equipos nacieron o lanzaron su primer LLM en los doce meses posteriores a ChatGPT. La frontera dejó de ser de un solo laboratorio.

La brecha se cierra

Diferencia entre el líder y su perseguidor · antes y después

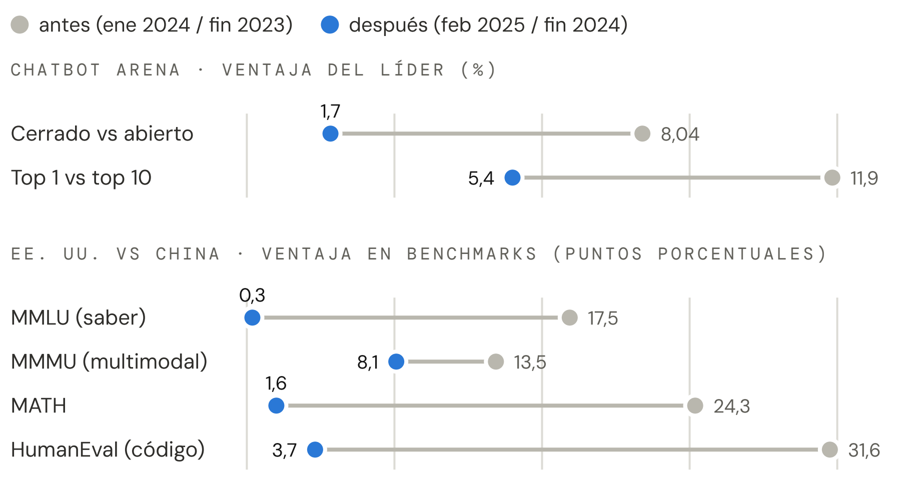

Fuente: Stanford HAI, *AI Index 2025*. En 2026 el mejor modelo abierto (DeepSeek V4) se ubica, por estimación propia, a 3–6 meses de la frontera cerrada.

03 LAS PERILLAS: CÓMO SE CONTROLA UN MODELO

Temperatura

El modelo no elige una palabra: produce una distribución de probabilidad sobre la siguiente. La temperatura la aplana o la afila antes de muestrear.

Siguiente palabra para `El cielo es ___`

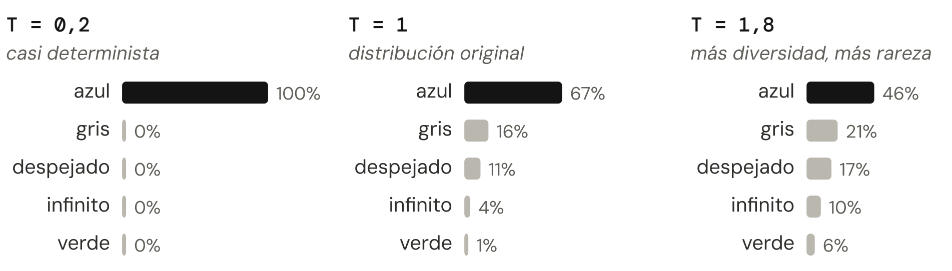

$$p_i = e^{z_i / T} \; / \; \Sigma_j \, e^{z_j / T}$$

z son los *logits*, la puntuación cruda que el modelo da a cada palabra candidata. Dividirlos por **T** antes del *softmax* estira las diferencias (T < 1: gana casi siempre la favorita) o las encoge (T > 1: las opciones raras ganan terreno). Con T → 0 el muestreo se vuelve *greedy*: siempre la palabra más probable.

Regla práctica: temperatura baja (0–0,3) para extraer datos, clasificar o programar; media (0,7–1) para conversar; alta (>1) para lluvia de ideas, con riesgo de incoherencia. El modelo es el mismo: cambia cómo se elige entre sus opciones.

Las demás perillas

Parámetros que se fijan en cada llamada a la API

`top-p` muestreo de núcleo	Solo se consideran los tokens más probables hasta sumar una probabilidad *p* (p. ej. 0,9). Corta la cola de opciones absurdas.
`top-k`	Solo los *k* tokens más probables entran al sorteo. Más tosco que top-p.
`max tokens`	Límite de longitud de la respuesta, y por tanto de su costo.
`esfuerzo` reasoning effort	En modelos razonadores, cuántos tokens de «pensamiento» gasta antes de responder. LOW rápido, barato MEDIUM equilibrio HIGH preciso, lento
`contexto` tokens visibles	Cuánto texto «ve» el modelo a la vez. Creció ~2.000×:

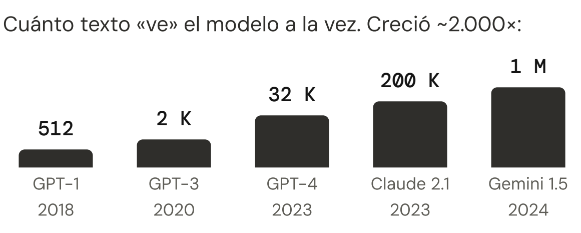

El cambio de 2024–2025: en los razonadores la temperatura suele venir fija o se ignora. La perilla que importa pasa a ser el **esfuerzo**: cuánto piensa, no cuán al azar elige.

04 EL LORO ESTOCÁSTICO: ¿MURIÓ?

LA TESIS · 2021

«Un loro estocástico»

> ***Un sistema que cose secuencias de formas lingüísticas observadas en sus datos, según información probabilística, sin ninguna referencia al significado.***

Bender, Gebru, McMillan-Major y Mitchell (FAccT 2021). Además de la crítica conceptual, el artículo advertía de sesgos heredados de los datos, costo ambiental y la **ilusión de comprensión** en quien lee.

En diciembre de 2022, Sam Altman respondió: *«i am a stochastic parrot, and so r u»*.

GOLPES AL LORO

Evidencia en contra de la tesis

Othello-GPT Li et al. · 2023
Entrenado solo con secuencias de jugadas, el modelo forma una representación interna del tablero que se puede leer y editar.

Planifica antes de hablar Anthropic · 2025
La interpretabilidad muestra que Claude elige la palabra que rimará *antes* de escribir el verso, y encadena pasos intermedios en preguntas de varios saltos.

Matemática de olimpiada IMO · 2025
Demostraciones escritas en lenguaje natural, a nivel de medalla de oro, sobre problemas inéditos.

Razonadores 2024 →
Más cómputo al pensar mejora las respuestas: un comportamiento difícil de explicar como simple repetición.

LO QUE SIGUE VIVO

Evidencia a favor de la tesis

Alucinaciones
Afirmaciones falsas con total fluidez. Disminuyen, pero no desaparecen.

La maldición de la inversión Berglund et al. · 2023
Aprender «A es B» no implica saber que «B es A».

Pensamiento infiel Anthropic · 2025
La cadena de razonamiento visible no siempre refleja lo que de verdad determinó la respuesta.

Fragilidad fuera de distribución Apple · 2025
The Illusion of Thinking: el rendimiento colapsa al subir la complejidad de rompecabezas. Resultado debatido.

VEREDICTO

No murió: se volvió más preciso

La versión fuerte, **«no hay nada dentro, solo estadística de superficie»**, no resiste la evidencia de interpretabilidad: hay representaciones internas y planificación. La versión débil, **«su razonamiento es frágil y su explicación no siempre es fiel a su cómputo»**, sigue abierta. Hoy la pregunta útil no es *si* el modelo entiende, sino *dónde* y *cuándo* se le puede confiar.

FUENTES · Vaswani et al. (2017) *Attention Is All You Need* · Kaplan et al. (2020) *Scaling Laws for Neural Language Models* · Bender et al. (2021) *On the Dangers of Stochastic Parrots* · Hoffmann et al. (2022) *Chinchilla* · Li et al. (2023) *Emergent World Representations* · Berglund et al. (2023) *The Reversal Curse* · DeepSeek-AI (2024–2026) informes técnicos V3, R1, V4 · Anthropic (2025) *Tracing the thoughts of a large language model* y *Reasoning models don't always say what they think* · Shojaee et al. (2025) *The Illusion of Thinking* · Stanford HAI (2025) *AI Index Report* · Fechas de 2026 contrastadas con anuncios y prensa especializada (oct 2026).

GRAFICS LAB
OCTUBRE 2026